

Instituto Tecnológico de Culiacán



**TECNOLÓGICO
NACIONAL DE MÉXICO**



Carrera: Ingeniería en Sistemas Computacionales

Materia: Inteligencia Artificial

Profesor: Zuriel Dathan Mora Felix

Tarea: Resumen sobre la Historia de la IA

Grupo:

11:00 AM – 12:00 PM

Equipo :

García Pérez José Ángel

Verdugo Bermúdez Sebastián

Resumen de la Historia de la IA

La primera etapa de la inteligencia artificial, conocida como la "Edad Oscura", fue un periodo en el que se empezaron a definir las bases teóricas del campo. En 1943, Warren McCulloch y Walter Pitts propusieron un modelo de redes neuronales artificiales basado en la idea de que las neuronas funcionan como interruptores que pueden estar encendidos o apagados. Demostraron que estas redes podían hacer cualquier cálculo computable, lo que ayudó a conectar el funcionamiento del cerebro con la computación. Aunque su modelo era una versión simplificada de las neuronas reales, fue un paso clave para el desarrollo de las redes neuronales artificiales. McCulloch es considerado uno de los pioneros de la inteligencia artificial, junto con Alan Turing.

En esta misma época, Alan Turing propuso en 1950 la famosa prueba de Turing, una forma práctica de medir la inteligencia de una máquina según su capacidad para imitar la conversación humana. Él creía que para finales del siglo XX una computadora podría superar esta prueba, evitando debates sobre qué es realmente la inteligencia y eliminando cualquier favoritismo hacia los humanos. Mientras tanto, John von Neumann hizo grandes aportes al desarrollo de las computadoras modernas, participando en el proyecto ENIAC y diseñando la EDVAC, que introdujo el concepto de programa almacenado. Además, apoyó los primeros intentos de usar redes neuronales en computadoras, mostrando su interés en la relación entre estas y la arquitectura computacional. Por otro lado, Claude Shannon, en 1950, estudió el ajedrez y demostró que una computadora tardaría millones de años en analizar todos los movimientos posibles si no usaba estrategias inteligentes. Su trabajo destacó la importancia de los métodos de búsqueda eficientes para resolver problemas complejos en inteligencia artificial.

Esta fase inicial de la IA venía acompañada de mucho entusiasmo y optimismo sobre lo que las computadoras podrían lograr al imitar la inteligencia humana. Un momento clave fue el Taller de Dartmouth en 1956, que marcó el inicio oficial de la IA como una disciplina científica. Organizado por John McCarthy, Marvin Minsky y Claude Shannon, este evento reunió a los principales investigadores del área y sentó las bases para el futuro de la inteligencia de las máquinas, el desarrollo de redes neuronales y la teoría de autómatas. John McCarthy, después de mudarse al MIT, creó LISP, uno de los lenguajes de programación más antiguos y de alto nivel. También propuso el "Advice Taker", un sistema que podía aprender nuevos conocimientos sin necesidad de ser reprogramado, lo que fue un gran avance para resolver problemas del mundo real de forma más flexible. Por su parte, Marvin Minsky, también en el MIT, desarrolló la teoría de "marcos" (frames), una nueva forma de organizar y usar el conocimiento que se alejaba de los enfoques más lógicos y tradicionales.

Allen Newell y Herbert Simon, de la Universidad Carnegie Mellon, crearon el Solucionador General de Problemas (GPS), un programa que imitaba la forma en que los humanos resuelven problemas. Su idea era separar la técnica de resolución de problemas de los datos y usar un método llamado "análisis de medios y fines" para reducir la diferencia entre el estado actual y el objetivo. Aunque fue un avance

importante, el GPS no logró resolver problemas complejos debido a su ineficiencia y a las limitaciones de las computadoras de la época. Mientras tanto, en el estudio de las redes neuronales, Frank Rosenblatt presentó el teorema de convergencia del perceptrón, un algoritmo que permitía a las máquinas aprender patrones ajustando sus conexiones. Por otro lado, Lotfi Zadeh introdujo los "conjuntos difusos", una idea clave para manejar la incertidumbre y la vaguedad en los sistemas de inteligencia artificial.

Con el tiempo, el entusiasmo por la inteligencia artificial comenzó a disminuir cuando se hizo evidente que los enfoques generales tenían muchas limitaciones. Aunque algunos programas podían resolver problemas sencillos, conocidos como "de juguete", ninguno era capaz de manejar problemas más complejos del mundo real. Muchos de estos programas usaban estrategias de búsqueda probando diferentes combinaciones de pasos, pero esto resultaba ineficiente cuando los problemas eran demasiado grandes, ya que requerían un tiempo exponencial para resolverse, incluso con las computadoras más avanzadas de la época. La falta de conocimiento específico en los programas también era un problema, ya que estos no podían adaptarse bien a diferentes situaciones y se volvían inútiles fuera de los casos para los que fueron diseñados.

Uno de los mayores fracasos fue la traducción automática. Al principio, los investigadores pensaban que bastaba con reemplazar palabras de un idioma a otro siguiendo reglas básicas, pero pronto se dieron cuenta de que la traducción requería mucho más que eso. Era necesario comprender el significado y el contexto de las palabras, algo que las IA de ese momento no podían hacer. Los errores eran comunes, y los resultados no tenían sentido en muchas ocasiones. Debido a estas dificultades, en 1966, el gobierno de Estados Unidos decidió cancelar la financiación de los proyectos de traducción automática, ya que los costos eran altos y los avances eran mínimos. Este fracaso dejó claro que la inteligencia artificial aún estaba lejos de alcanzar un nivel de comprensión similar al humano.

En 1971, el Informe Lighthill en el Reino Unido puso en duda la necesidad de una disciplina separada para la inteligencia artificial, argumentando que no se habían logrado avances significativos en la resolución de problemas complejos. Este informe provocó una gran reducción en la financiación de proyectos de IA tanto en el Reino Unido como en otras partes del mundo, lo que llevó a un período de estancamiento conocido como el "invierno de la IA". La comunidad científica empezó a darse cuenta de que los métodos generales de la época no eran suficientes y que se necesitaba un enfoque más práctico, basado en el conocimiento específico de cada problema. Este cambio de mentalidad marcó un punto de inflexión en la historia de la IA, dando paso a nuevas ideas que reconocían la importancia del contexto y la especialización para desarrollar sistemas más efectivos y útiles.

A principios de la década de 1970 y hasta mediados de la década de 1980, la atención se centró en los sistemas expertos, un cambio de paradigma hacia el conocimiento

específico del dominio. Los investigadores se dieron cuenta de que para que las máquinas inteligentes fueran exitosas, el dominio del problema debía ser lo suficientemente restringido. Por lo que esto marcó un cambio de paradigma desde los métodos generales con escaso conocimiento hacia técnicas intensivas en conocimiento y específicas del dominio. A diferencia de los primeros enfoques de la IA, que intentaban desarrollar métodos generales de resolución de problemas con conocimientos débiles, los sistemas expertos se enfocaron en dominios limitados y aprovecharon reglas específicas derivadas de la experiencia humana. Un ejemplo clave fue DENDRAL, un sistema desarrollado en la Universidad de Stanford para analizar estructuras químicas con el apoyo de la NASA, el cual utilizó reglas heurísticas basadas en el conocimiento de expertos para reducir la complejidad del problema. Otro avance crucial fue MYCIN, un sistema experto diseñado para el diagnóstico de enfermedades infecciosas en la sangre, que introdujo el uso de factores de certeza para manejar la incertidumbre en el diagnóstico médico. Estos sistemas demostraron que el éxito en IA no dependía solo de algoritmos avanzados, sino de la capacidad de capturar y estructurar el conocimiento humano en reglas computables. Sin embargo, presentaban limitaciones, como su rigidez y la dificultad de adquirir y validar el conocimiento de los expertos, lo que más tarde impulsó la integración con otras técnicas, como redes neuronales y lógica difusa. Este periodo fue fundamental para la maduración de la IA aplicada, sentando las bases para el desarrollo de sistemas de apoyo a la toma de decisiones en diversas disciplinas.

El renacimiento de las redes neuronales a mediados de los años 1980 marcó un resurgimiento en la inteligencia artificial tras la decepción con los sistemas expertos. Aunque los primeros modelos de redes neuronales artificiales fueron propuestos por McCulloch y Pitts en 1943, la investigación en este campo se estancó durante décadas debido a limitaciones matemáticas y tecnológicas. Sin embargo, con el avance del hardware y el aumento del poder de cómputo, los científicos retomaron el interés en estas redes, impulsados por la necesidad de sistemas que pudieran aprender y adaptarse sin depender exclusivamente de reglas predefinidas. John Hopfield introdujo las redes de retroalimentación en 1982, mientras que Rumelhart y McClelland revitalizaron el concepto con el algoritmo de retropropagación del error en 1986, lo que permitió el entrenamiento efectivo de redes neuronales multicapa. Este avance facilitó la creación de modelos más sofisticados capaces de reconocer patrones complejos en grandes volúmenes de datos, lo que más tarde revolucionó campos como el reconocimiento de voz, la visión por computadora y la predicción financiera. Aunque en sus inicios estas redes fueron vistas con escepticismo, su capacidad para aprender de la experiencia sin intervención humana directa las convirtió en una herramienta poderosa, sentando las bases para el aprendizaje profundo y la inteligencia artificial moderna.

Por otro lado, la computación evolutiva, surgida en los años 70 ciertamente en paralelo con los sistemas expertos, se inspiró en los procesos biológicos de evolución y selección natural para desarrollar algoritmos capaces de aprender y adaptarse mediante la práctica. En lugar de depender de reglas fijas o aprendizaje supervisado, estos métodos simulan la evolución de una población de soluciones a un problema,

evaluando su desempeño, generando nuevas variantes y seleccionando las más aptas en cada iteración. Entre las principales técnicas de este enfoque están los algoritmos genéticos, introducidos por John Holland en 1975, que emplean mecanismos como la mutación y el cruce para optimizar soluciones, así como las estrategias evolutivas, propuestas por Ingo Rechenberg y Hans-Paul Schwefel, y la programación genética, desarrollada por John Koza en los años 90, que busca evolucionar programas informáticos en lugar de parámetros numéricos. Estos métodos demostraron ser altamente efectivos en problemas complejos de optimización y búsqueda, donde otros enfoques tradicionales resultaban ineficientes. A pesar de su éxito en ingeniería y modelado de sistemas, la computación evolutiva tiene limitaciones, como el alto costo computacional y la dificultad para garantizar soluciones óptimas. No obstante, su capacidad para encontrar soluciones robustas en entornos inciertos la ha convertido en una herramienta clave en inteligencia artificial, influyendo en áreas como la robótica, la bioinformática y la optimización de redes neuronales.

Así mismo la nueva era de la ingeniería del conocimiento, que comenzó a finales de los años 1980, representó una evolución significativa en la inteligencia artificial al integrar enfoques más flexibles y adaptativos, como la lógica difusa y la computación con palabras. Esta etapa surgió como una respuesta a las limitaciones de los sistemas expertos tradicionales, que se basaban en reglas rígidas y en la adquisición compleja de conocimiento experto. La lógica difusa mencionada anteriormente permitió manejar conceptos imprecisos y subjetivos, como "rápido" o "lento", que reflejan mejor la forma en que los humanos piensan y toman decisiones. Esto abrió nuevas posibilidades para modelar problemas complejos y dinámicos, especialmente en sistemas de control y toma de decisiones.

Finalmente, la computación con palabras permitió que las máquinas entendieran y procesaran descripciones cualitativas en lugar de solo datos numéricos, haciendo los sistemas más "humanos" en su interacción. Esta etapa también vio cómo las tecnologías anteriormente competidoras, como las redes neuronales, los sistemas expertos y la lógica difusa, comenzaron a complementarse en lugar de rivalizar. Los sistemas híbridos combinaban la adaptabilidad de las redes neuronales con la interpretabilidad de las reglas difusas, logrando soluciones más robustas y flexibles.

Estos progresos permitieron que la IA evolucionara hacia sistemas más flexibles y adaptativos, integrando tecnologías como la lógica difusa y la computación con palabras, abriendo nuevas posibilidades para resolver problemas complejos.