



**TECNOLÓGICO  
NACIONAL DE MÉXICO**



**Instituto Tecnológico de Culiacán**

**Carrera:** Ingeniería en Sistemas Computacionales

**Materia:** Inteligencia Artificial

**Profesor:** Zuriel Dathan Mora Félix

**Tarea: Paradigma Conexionista y Simbólico. Tabla de Similitudes y Diferencias entre el Modelo Cognitivo y las Fases del Aprendizaje Automático**

**Grupo:**

11:00 AM – 12:00 PM

**Equipo:**

García Pérez José Ángel

Verdugo Bermúdez Sebastián

# **Paradigma Conexionista**

Este es un paradigma basado en la idea de que la inteligencia emerge de redes de unidades simples interconectadas, inspiradas en el funcionamiento del cerebro humano. A diferencia del enfoque simbólico, que usa reglas y representaciones explícitas, el conexionismo se basa en el procesamiento distribuido y el aprendizaje a través de la modificación de pesos en redes neuronales artificiales.

## **Ejemplos Prácticos**

### **Reconocimiento de Imágenes en Google Photos**

#### **Descripción:**

Google Photos utiliza redes neuronales profundas para clasificar y reconocer rostros, objetos y escenas en imágenes subidas por los usuarios. Esto permite organizar fotos automáticamente según categorías como "playa", "perros" o "familiares".

#### **Aplicación del paradigma conexionista**

El sistema se entrena con redes neuronales convolucionales (CNN), que aprenden patrones visuales en capas sucesivas. A través del ajuste de pesos en cada neurona, el modelo reconoce características como bordes, texturas y formas, lo que permite identificar objetos y personas con alta precisión.

#### **Beneficios de este paradigma**

##### **Alta precisión en la clasificación**

Gracias a las redes neuronales profundas, el sistema puede reconocer rostros y objetos con gran exactitud, incluso si hay variaciones en iluminación, ángulos o expresiones faciales.

##### **Búsqueda eficiente y rápida**

Permite encontrar fotos de eventos o personas específicas con solo escribir una palabra clave, sin necesidad de explorar cientos de imágenes manualmente.

##### **Automatización y facilidad de uso**

El usuario no necesita etiquetar fotos manualmente, ya que la IA hace el trabajo de organización por él. Esto ahorra tiempo y mejora la experiencia.

#### **Limitaciones de este paradigma:**

##### **Dependencia de grandes volúmenes de datos**

El modelo necesita millones de imágenes de entrenamiento para ser preciso. Si se entrena con datos limitados, su capacidad de reconocimiento será deficiente.

## **Privacidad y ética**

El reconocimiento facial ha generado preocupaciones sobre la privacidad. Algunos usuarios no se sienten cómodos con que su rostro sea identificado automáticamente, y existe el riesgo de mal uso de esta tecnología en vigilancia.

## **Posibles sesgos en la identificación**

Si el conjunto de datos de entrenamiento tiene un sesgo (por ejemplo, más imágenes de personas de un grupo étnico que de otros), la IA puede tener dificultades para reconocer correctamente ciertos rostros o escenarios.

## **Consumo computacional elevado**

El entrenamiento y la inferencia en redes neuronales profundas requieren servidores con GPUs y TPUs avanzadas, lo que implica un alto costo energético y computacional.

# **Predicción de Enfermedades en la Medicina con el Enfoque Conexionista**

En el campo de la medicina, la inteligencia artificial se utiliza para predecir enfermedades analizando imágenes médicas, datos clínicos y registros de pacientes. Un caso específico es el uso de redes neuronales para la detección temprana de enfermedades como el cáncer de mama, la retinopatía diabética y enfermedades cardiovasculares.

Por ejemplo, sistemas como Google DeepMind Health y IBM Watson Health han desarrollado modelos de IA capaces de analizar radiografías, resonancias magnéticas y tomografías computarizadas para identificar patrones que los médicos podrían pasar por alto. Un sistema de este tipo puede analizar una mamografía y detectar signos de cáncer de mama antes de que sean evidentes para un radiólogo humano.

## **Aplicación del paradigma conexionista**

El enfoque conexionista en este contexto se basa en redes neuronales profundas, especialmente redes neuronales convolucionales (CNN) y redes neuronales recurrentes (RNN), que analizan imágenes médicas y datos clínicos.

## **Beneficios de este paradigma**

### **Mayor precisión y reducción de errores**

Al ser entrenados con grandes volúmenes de datos, los modelos pueden reducir errores en el diagnóstico, complementando el trabajo de los médicos.

## **Velocidad en el análisis**

Un radiólogo puede tardar minutos o incluso horas en analizar múltiples imágenes, mientras que la IA puede hacerlo en segundos, optimizando el tiempo de atención médica.

## **Escalabilidad y acceso a diagnósticos avanzados**

En regiones con escasez de especialistas médicos, los sistemas de IA pueden proporcionar diagnósticos preliminares y ayudar a tomar decisiones médicas en zonas rurales o con pocos recursos.

## **Limitaciones de este paradigma**

### **Falta de explicabilidad ("caja negra")**

Las redes neuronales profundas pueden hacer predicciones precisas, pero a menudo no pueden explicar exactamente por qué tomaron una decisión, lo que dificulta la confianza de los médicos en los resultados.

### **No reemplaza la experiencia médica**

Aunque la IA es una herramienta poderosa, no reemplaza el juicio de un médico experimentado. Su función es apoyar y complementar el diagnóstico, no tomar decisiones definitivas por sí sola.

### **Dependencia de grandes volúmenes de datos**

Para que la IA tenga una alta precisión, necesita millones de imágenes médicas etiquetadas, lo cual puede ser difícil de obtener debido a restricciones de privacidad y a la falta de datos estandarizados en hospitales.

### **Posibles sesgos en los datos de entrenamiento**

Si los datos de entrenamiento no incluyen suficiente diversidad (por ejemplo, más imágenes de un tipo de población que de otra), la IA puede tener dificultades para generalizar y hacer diagnósticos precisos en todos los pacientes.

## Paradigma Simbólico

La Inteligencia Artificial Simbólica, también llamada GOFAI (*Good Old-Fashioned AI*), se basa en el uso de símbolos y reglas para representar el conocimiento y tomar decisiones. En lugar de aprender de los datos como lo hacen las redes neuronales, esta IA sigue reglas predefinidas creadas por humanos.

Básicamente, funciona como un sistema basado en reglas donde cada símbolo representa algo del mundo real, y las reglas definen cómo se deben manipular esos símbolos para resolver problemas. Es como si se le dijera a la computadora exactamente qué hacer en cada situación en lugar de que ella aprenda por sí misma.

### Ejemplos prácticos

#### MYCIN, el Sistema Experto para Diagnóstico de Infecciones

##### Descripción:

Uno de los primeros sistemas expertos en medicina fue **MYCIN**, desarrollado en la Universidad de Stanford en la década de 1970. Su objetivo era ayudar a los médicos a diagnosticar infecciones bacterianas en la sangre y recomendar tratamientos antibióticos adecuados.

##### Aplicación del paradigma simbólico

MYCIN funcionaba a través de una **base de conocimiento** compuesta por reglas médicas diseñadas por especialistas en enfermedades infecciosas. Estas reglas seguían una estructura lógica del tipo *si-entonces*, permitiendo al sistema analizar los síntomas de un paciente y llegar a una posible conclusión. Por ejemplo, si un paciente presentaba fiebre alta y sus cultivos de sangre daban positivo para ciertas bacterias, MYCIN determinaba que era probable que tuviera una infección en la sangre.

Para procesar esta información, MYCIN utilizaba un **motor de inferencia** que evaluaba los síntomas y las pruebas médicas del paciente. Aplicando sus reglas predefinidas, el sistema podía identificar enfermedades y recomendar tratamientos. Además, realizaba preguntas adicionales al médico, como la edad del paciente o su historial clínico, con el fin de refinar el diagnóstico y hacer una recomendación más precisa.

##### Beneficios del Uso de MYCIN

##### Alta Precisión en Diagnósticos

En algunos casos, su precisión superaba la de médicos generales en el tratamiento de infecciones.

## **Transparencia Total**

Los médicos podían ver exactamente cómo MYCIN llegaba a un diagnóstico y decidir si seguir su recomendación.

## **Útil para Médicos No Especialistas**

Podía asistir a médicos en hospitales con pocos especialistas en enfermedades infecciosas.

## **Limitaciones de MYCIN**

### **No Aprendía de Nuevos Casos**

Necesitaba ser actualizado manualmente cuando aparecían nuevas enfermedades o tratamientos.

### **No Sustituyó a los Médicos**

Era una herramienta de apoyo, pero los médicos seguían teniendo la última palabra en el diagnóstico.

### **Dificultad para Generalizar**

Funcionaba bien con infecciones en la sangre, pero no podía diagnosticar otras enfermedades sin agregar muchas más reglas.

## **Juego de Estrategia en Tiempo Real (RTS)**

### **Descripción:**

En un juego de estrategia en tiempo real (RTS) como Command & Conquer o StarCraft, los jugadores toman decisiones tácticas y estratégicas en tiempo real, gestionando recursos, construyendo unidades y defendiendo sus territorios. En este tipo de juego, la inteligencia artificial simbólica se puede utilizar para controlar las acciones de las unidades no controladas por los jugadores, como el movimiento de las tropas, la construcción de edificios y la toma de decisiones sobre el ataque o la defensa, todo basado en reglas lógicas definidas.

### **Aplicación del paradigma simbólico**

En un juego de estrategia en tiempo real (RTS), la base de conocimiento se compone de reglas que dictan el comportamiento de las unidades, como las reglas de movimiento (buscar recursos o acercarse al enemigo), construcción (crear unidades o edificios según los recursos y amenazas) y combate (atacar si el enemigo está cerca o retirarse si la salud es baja).

El motor de inferencia procesa el estado del juego y aplica estas reglas para tomar decisiones. Por ejemplo, si una unidad enemiga entra en el rango de visión, la IA ordena atacar, o si las unidades de recursos están en peligro, las mueve a una zona segura.

La explicabilidad es una ventaja de la IA simbólica, ya que todas las decisiones son transparentes y se puede explicar por qué la IA hizo una acción determinada, como "la IA decidió atacar porque la unidad enemiga tenía menos del 30% de salud". Esto permite a los diseñadores ajustar y comprender fácilmente el comportamiento de la IA.

### **Beneficios del Paradigma Simbólico:**

#### **Alta Transparencia**

Las reglas de la IA son claras y fáciles de entender, lo que permite a desarrolladores y jugadores comprender y modificar cómo se toman las decisiones.

#### **Control Total sobre el Comportamiento**

Los desarrolladores pueden ajustar fácilmente las reglas de la IA, adaptándola a los objetivos del juego, como aumentar la dificultad o hacerla más predecible.

#### **Facilidad para Realizar Pruebas**

Las reglas explícitas permiten realizar pruebas sencillas, facilitando la identificación y corrección de problemas rápidamente.

#### **Comportamiento Consistente**

A diferencia del aprendizaje automático, la IA simbólica asegura un comportamiento constante y predecible en todo momento.

### **Limitaciones del Paradigma Simbólico**

#### **Escalabilidad Limitada**

A medida que el juego se vuelve más complejo, gestionar un gran número de reglas se vuelve difícil y consume mucho tiempo.

#### **Falta de Adaptabilidad**

La IA no puede aprender de sus errores ni adaptarse sin intervención humana, lo que limita su capacidad para evolucionar frente a jugadores avanzados.

## **Desempeño en Situaciones No Planificadas**

Si la IA enfrenta situaciones no cubiertas por sus reglas, podría no reaccionar adecuadamente, perdiendo efectividad frente a estrategias impredecibles.

## **Etapas del aprendizaje automático**

El proceso de aprendizaje automático en grandes conjuntos de datos se puede dividir en varias etapas que ayudan a construir un modelo que pueda hacer predicciones o tomar decisiones.

### **Adquisición de Datos**

El primer paso consiste en obtener los datos que se usarán para entrenar el modelo. Esto puede incluir datos de diversas fuentes como sensores, registros, imágenes, texto, o cualquier tipo de información relevante para el problema que se desea resolver. Es importante asegurarse de que los datos sean representativos del contexto en el que se utilizará el modelo.

### **Preprocesamiento de Datos**

Una vez que se tienen los datos, es necesario limpiarlos y transformarlos para que sean adecuados para el análisis. Esto implica eliminar o corregir datos erróneos, manejar valores faltantes, y transformar los datos para que sean fáciles de trabajar con los algoritmos de aprendizaje automático. También se puede normalizar o escalar los datos para mejorar el rendimiento del modelo.

### **Entrenamiento del Modelo**

Después de preparar los datos, se selecciona un modelo adecuado que se ajuste al problema. Dependiendo de la naturaleza del problema (clasificación, regresión, etc.), se elige un tipo de modelo, como redes neuronales, máquinas de vectores de soporte o árboles de decisión. Luego, se entrena este modelo usando los datos preprocesados, de manera que el modelo pueda aprender patrones y relaciones que le permitan hacer predicciones.

### **Evaluación del Modelo**

Una vez entrenado el modelo, es crucial evaluar su rendimiento para asegurarse de que está funcionando correctamente. Esto se realiza usando un conjunto de datos de prueba, diferente al utilizado en el entrenamiento. Se analizan métricas como precisión, recall, o la puntuación F1, para medir qué tan bien el modelo predice los resultados. Esta etapa es importante para verificar que el modelo no esté sobreajustado a los datos de entrenamiento y que sea capaz de generalizar bien a nuevos datos.



## Implementación del Modelo

Finalmente, el modelo entrenado se implementa en un entorno real o de producción, donde puede empezar a hacer predicciones o tomar decisiones basadas en nuevos datos que recibe. Una vez implementado, es importante seguir supervisando el rendimiento del modelo y hacer ajustes cuando sea necesario. También se debe actualizar el modelo con nuevos datos para asegurarse de que siga siendo relevante y preciso con el tiempo.

Estas etapas forman un ciclo continuo, ya que siempre es posible volver a alguno de los pasos anteriores para mejorar el modelo o adaptarlo a nuevos datos. El proceso requiere pruebas, ajustes y mejoras continuas para que el modelo sea lo más eficaz posible en el contexto en el que se utilice.

### Similitudes y Diferencias del Modelo Cognitivo y las Etapas del Aprendizaje Automático

Etapas del Aprendizaje Automático	Componente del Modelo Cognitivo	Similitudes	Diferencias
Adquisición de Datos	Percepción	Ambas etapas comienzan con la recopilación de información sobre el entorno. En el aprendizaje automático, esto se hace mediante la recolección de datos estructurados (imágenes, texto, números), mientras que la percepción humana se refiere a la recolección de estímulos a través de los sentidos (vista, oído, tacto).	El proceso de adquisición de datos en el aprendizaje automático se basa en datos cuantificables y etiquetados, mientras que la percepción humana es mucho más compleja, involucrando interpretación subjetiva, contextos emocionales y sociales.
Preprocesamiento de Datos	Atención y Codificación	Ambas etapas filtran información y la organizan para su procesamiento posterior. En el preprocesamiento de datos, se eliminan ruidos o datos irrelevantes	El preprocesamiento de datos es un proceso técnico y matemático, que involucra la transformación de datos brutos en formatos utilizables

		(limpieza de datos), y en la atención humana, se seleccionan estímulos relevantes para ser procesados conscientemente.	por los modelos. Mientras tanto, la atención humana está influenciada por factores psicológicos, culturales, emocionales y contextuales.
<b>Entrenamiento del Modelo</b>	Aprendizaje	Ambas etapas implican el proceso de adquirir conocimiento y mejorar el rendimiento en tareas específicas. El entrenamiento del modelo tiene como objetivo ajustar los parámetros del modelo para optimizar su rendimiento en una tarea dada, mientras que el aprendizaje humano implica la asimilación de experiencias y la mejora del desempeño basado en la interacción con el entorno.	El entrenamiento del modelo utiliza algoritmos matemáticos y estadísticos (como regresión, redes neuronales, entre otros) para ajustar parámetros. El aprendizaje humano involucra la formación de recuerdos, la adaptación cognitiva y la influencia de factores como emociones, motivación y entorno.
<b>Evaluación del Modelo</b>	Evaluación y Retroalimentación	Ambas etapas buscan evaluar el desempeño y utilizar los resultados para realizar ajustes. En el aprendizaje automático, se evalúan métricas como la precisión, el recall o el F1-score, y en los modelos cognitivos humanos se usan sistemas de	La evaluación en el aprendizaje automático se basa en métricas cuantitativas precisas, como la exactitud o el error. La evaluación humana, en cambio, es mucho más subjetiva, influenciada por emociones, juicios personales y el contexto en el que

		retroalimentación social, emocional y personal.	se da el aprendizaje. Además, la retroalimentación humana puede estar influenciada por la cultura y las experiencias previas.
<b>Implementación del Modelo</b>	Acción y Aplicación	Ambas etapas tienen como fin poner en práctica el conocimiento adquirido. La implementación del modelo en IA se refiere a desplegar el modelo entrenado en un entorno real para que realice tareas específicas, como la predicción de ventas o la detección de fraudes. En el caso humano, la acción y aplicación se refiere a cómo un individuo utiliza lo aprendido para tomar decisiones y actuar en el mundo.	En el aprendizaje automático, la implementación es un proceso automatizado en sistemas informáticos, que se integra en software, aplicaciones o dispositivos. La acción humana, sin embargo, está influenciada por factores como motivaciones personales, emociones, capacidades físicas, contextos sociales y culturales.

## Referencias Bibliográficas

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... & Rabinovich, A. (2015). Going deeper with convolutions. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 1-9).

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097-1105.

Google Photos. (s.f.). <https://photos.google.com/>

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Goldstein, E. B. (2014). *Cognitive psychology: Connecting mind, research, and everyday experience* (4th ed.). Wadsworth Cengage Learning.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Anderson, J. R. (2015). *Cognitive psychology and its implications* (8th ed.). Worth Publishers.

Daniel. (2024, Octubre 4). *IA Simbólica: ¿Qué es?* Formación En Ciencia De Datos | DataScientest.com. <https://datascientest.com/es/ia-simbolica-que-es>

Sirovy, L. (2024, Junio 10). *La IA simbólica frente al aprendizaje automático en el procesamiento del lenguaje natural*. Inbenta.  
<https://www.inbenta.com/es/articles/symbolic-ai-vs-machine-learning-in-natural-language-processing/>

Azcoitia, S. S. (2023, June 29). MYCIN, El comienzo de la Inteligencia Artificial en el mundo de la medicina. *Telefónica Tech*. <https://telefonicatech.com/blog/mycin-el-comienzo-de-la-inteligencia>

*¿Qué es el aprendizaje automático? | Glosario*. (n.d.). HPE México.  
<https://www.hpe.com/mx/es/what-is/machine-learning.html>

*1.6 El Modelo Cognoscitivo – Sistemas e Informatica*. (n.d.).  
<https://sistemasinformatica.istmo.tecnm.mx/cursos/inteligencia-artificial/1-introduccion-a-la-inteligencia-artificial/1-6-el-modelo-cognoscitivo/>